21-JavaScript编译器(二): V8的解释器和优化编译器

你好,我是宫文学。通过前一讲的学习,我们已经了解了V8的整个编译过程,并重点探讨了一个问题,就是**V8的编译速度为什么那么快**。

V8把解析过程做了重点的优化,解析完毕以后就可以马上通过Ignition解释执行了。这就让JavaScript可以 快速运行起来。

今天这一讲呢,我们重点来讨论一下,**V8的运行速度为什么也这么快**,一起来看看V8所采用的优化技术。

上一讲我也提及过,V8在2008年刚推出的时候,它提供了一个快速编译成机器码的编译器,虽然没做太多优化,但性能已经是当时其他JavaScript引擎的10倍了。而现在,V8的速度又是2008年刚发布时候的10倍。那么,是什么技术造成了这么大的性能优化的呢?

这其中,**一方面原因,是TurboFan这个优化编译器,采用了很多的优化技术。**那么,它采用了什么优化算法?采用了什么IR?其优化思路跟Java的JIT编译器有什么相同点和不同点?

另一方面,最新的Ignition解释器,虽然只是做解释执行的功能,但竟然也比一个基础的编译器生成的代码 慢不了多少。这又是什么原因呢?

所以今天,我们就一起把这些问题都搞清楚,这样你就能全面了解V8所采用的编译技术的特点了,你对动态类型语言的编译,也就能有更深入的了解,并且这也有助于你编写更高效的JavaScript程序。

好,首先,我们来了解一下TurboFan的优化编译技术。

TurboFan的优化编译技术

TurboFan是一个优化编译器。不过它跟Java的优化编译器要完成的任务是不太相同的。因为JavaScript是动态类型的语言,所以如果它能够推断出准确的类型再来做优化,就会带来巨大的性能提升。

同时,TurboFan也会像Java的JIT编译器那样,基于IR来运行各种优化算法,以及在后端做指令选择、寄存器分配等优化。所有的这些因素加起来,才使得TurboFan能达到很高的性能。

我们先来看看V8最特别的优化,也就是通过对类型的推理所做的优化。

基于推理的优化(Speculative Optimazition)

对于基于推理的优化,我们其实并不陌生。在研究<u>Java的JIT编译器</u>时,你就发现了Graal会针对解释器收集的一些信息,对于代码做一些推断,从而做一些激进的优化,比如说会跳过一些不必要的程序分支。

而JavaScript是动态类型的语言,所以对于V8来说,最重要的优化,就是能够在运行时正确地做出类型推断。举个例子来说,假设示例函数中的add函数,在解释器里多次执行的时候,接受的参数都是整型,那么TurboFan就处理整型加法运算的代码就行了。这也就是上一讲中我们生成的汇编代码。

```
function add(a,b){
  return a+b;
}
```

```
for (i = 0; i<100000; i++){
   if (i%1000==0)
      console.log(i);

add(i, i+1);
}</pre>
```

```
70 4c8bc7 REX.W movq r8,rdi
73 41d1f8 sarl r8, 1
76 4c8bc9 REX.W movq r9,rcx
79 41d1f9 sarl r9, 1
7c 4503c1 addl r8,r9
```

但是,如果不在解释器里执行,直接要求TurboFan做编译,会生成什么样的汇编代码呢?

你可以在运行d8的时候,加上"-always-opt"参数,这样V8在第一次遇到add函数的时候,就会编译成机器码。

```
./d8 --trace-opt-verbose \
    --trace-turbo \
    --turbo-filter=add \
    --print-code \
    --print-opt-code \
    --code-comments \
    --always-opt \
    add.js
```

这一次生成的汇编代码,跟上一讲生成的就不一样了。由于编译器不知道add函数的参数是什么类型的,所以实际上,编译器是去调用实现Add指令的内置函数,来生成了汇编代码。

这个内置函数当然支持所有加法操作的语义,但是它也就无法启动基于推理的优化机制了。这样的代码,跟解释器直接解释执行,性能上没太大的差别,因为它们本质上都是调用一个全功能的内置函数。

```
REX.W movq rdx,[rbp+0x18]
                   REX.W movq rax,[rbp+0x10] ←
   488b4510
5d 48be510f2408ae180000 REX.W movq rsi,0x18ae08240f51 ;; object: 0x18ae08240f51 <NativeContext[257]>
 -- Inlined Trampoline to Add
                                                      函数的上下文对象,加载到rsi寄存器
67 49ba8086b40a01000000 REX.W movq r10,0x10ab48680 (Add)
71 41ffd2 call r10 Add内置图
                                                                ;; off heap target
                   call r10 <
                                                      · Add内置函数的地址,加载到r10寄存器
                                 〜 调用Add内置函数
   <not inlined:34> --
                REX.W movq rsp,rbp
74 488be5
                                           = 还原栈指针,准备退出函数
    5d
77
                   pop rbp
    c21800
                   ret 0x18
                                     - 退出函数 . 返回
```

而推理式优化的版本则不同,它直接生成了针对整型数字进行处理的汇编代码:

```
70
    4c8bc7
                   REX.W movq r8, rdi ← 第1个参数,加载到r8寄存器。注意,这里是从物理寄存器取参
73
    41d1f8
                   sarl r8, 1
                                           向右移1位。
                   REX.W movq r9,rcx <
76
    4c8bc9
                                           第2个参数,加载到r9寄存器。
79
    41d1f9
                    sarl r9, 1
                                           向右移1位。
    4503c1
                   addl r8,r9
                                            把r9加到r8上
```

我来给你解释一下这几行指令的意思:

- 第1行和第3行,是把参数1和参数2分别拷贝到r8和r9寄存器。**注意**,这里是从物理寄存器里取值,而不是像前一个版本一样,在栈里取值。前一个版本遵循的是更加保守和安全的调用约定。
- 第2行和第4行,是把r8和r9寄存器的值向右移1位。
- 第5行,是把r8和r9相加。

看到这里,你可能就发现了一个问题:**只是做个简单的加法而已,为什么要做移位操作呢?**实际上,如果你熟悉汇编语言的话,要想实现上面的功能,其实只需要下面这两行代码就可以了:

```
movq rax, rdi #把参数1拷贝到rax寄存器
addq rax, rcx #把参数2加到rax寄存器上,作为返回值
```

那么,多出来的移位操作是干什么的呢?

这就涉及到了V8的**内存管理机制**。原来,V8对象都保存在堆中。在栈帧中保存的数值,都是指向堆的指针。垃圾收集器可以通过这些指针,知道哪些内存对象是不再被使用的,从而把它们释放掉。我们前面学过,Java的虚拟机和Python对于对象引用,本质上也是这么处理的。

但是,这种机制对于基础数据类型,比如整型,就不太合适了。因为你没有必要为一个简单的整型数据在堆中申请内存,这样既浪费内存,又降低了访问效率,V8需要访问两次内存才能读到一个整型变量的值(第一次读到地址,第二次根据该地址到堆里读到值)。你记得,Python就是这么访问基础数据的。

V8显然不能忍受这种低效的方式。它采用的优化机制,是一种被广泛采用的技术,叫做**标记指针**(Tagged Pointer)或者**标记值**(Tagged Value)。《<u>Pointer Compression in V8</u>》这篇文章,就介绍了V8中采用 Tagged Pointer技术的细节。

比如说,对于一个32位的指针值,它的最低位是标记位。当标记位是0的时候,前31位是一个短整数(简写为Smi);而当标记位是1的时候,那么前31位是一个地址。这样,V8就可以用指针来直接保存一个整数值,用于计算,从而降低了内存占用,并提高了运行效率。



图1:用标记指针技术来表示一个整数

好了,现在你已经理解了V8的推理式编译的机制。那么,还有什么手段能提升代码的性能呢?

当然,还有基于IR的各种优化算法。

IR和优化算法

在讲Java的JIT编译器时我就提过,V8做优化编译时采用的IR,也是基于Sea of Nodes的。

你可以回忆一下Sea of Nodes的特点:合并了数据流图与控制流图;是SSA形式;没有把语句划分成基本块。

它的重要优点,就是优化算法可以自由调整语句的顺序,只要不破坏数据流图中的依赖关系。在Sea of Nodes中,没有变量(有时也叫做寄存器)的概念,只有一个个数据节点,所以对于死代码删除等优化方法来说,它也具备天然的优势。

说了这么多,那么要如何查看TurboFan的IR呢?一个好消息是,V8也像GraalVm一样,提供了一个图形化的工具,来查看TurboFan的IR。这个工具是turbolizer,它位于V8源代码的tools/turbolizer目录下。你可以按照该目录下的README.md文档,构建一下该工具,并运行它。

```
python -m SimpleHTTPServer 8000
```

它实际启动了一个简单的Web服务。你可以在浏览器中输入"0.0.0.0:8000",打开turbolizer的界面。

在运行d8的时候,如果带上参数"–trace-turbo",就会在当前目录下输出一个.json文件,打开这个文件 就能显示出TurboFan的IR来。比如,上一讲的示例程序add.js,所显示出的add函数的IR:

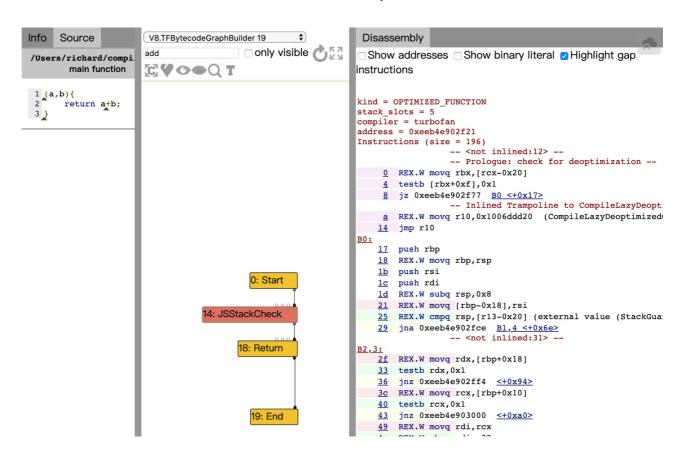


图2: 在turbolizer中显示add函数的IR

界面中最左边一栏是源代码,中间一栏是IR,最右边一栏是生成的汇编代码。

上图中的IR只显示了控制节点。你可以在工具栏中找到一个按钮,把所有节点都呈现出来。在左侧的Info标签页中,还有一些命令的快捷键,你最好熟悉一下它们,以便于控制IR都显示哪些节点。这对于一个大的IR 图来说很重要,否则你会看得眼花缭乱:

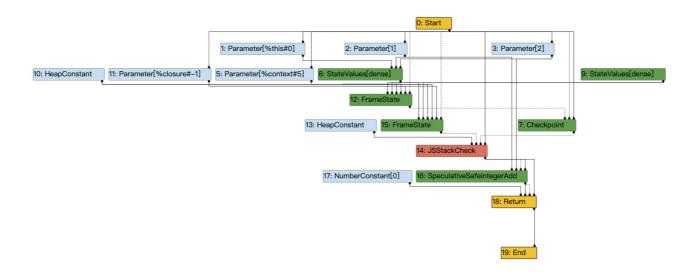


图3: 完整展开的add函数的IR

在这个图中,不同类型的节点用了不同的颜色来区分:

• 黄色:控制流的节点,比如Start、End和Return;

• 淡蓝色: 代表一个值的节点;

• 红色: JavaScript层级的操作,比如JSEqual、JSToBoolean等;

• 深蓝色: 代表一种中间层次的操作,介于JavaScript层和机器层级中间;

• 绿色: 机器级别的语言,代表一些比较低层级的操作。

在turbolizer的界面上,还有一个下拉菜单,里面有多个优化步骤。你可以挨个点击,看看经过不同的优化步骤以后,IR的变化是什么样子的。

√ V8.TFBytecodeGraphBuilder 19 find with rec V8.TFInlining 22 V8.TFEarlyTrimming 22 V8.TFTyper 22 V8.TFTypedLowering 22 V8.TFLoopPeeling 22 V8.TFLoadElimination 22 V8.TFEscapeAnalysis 22 V8.TFSimplifiedLowering 35 V8.TFUntyper 35 V8.TFGenericLowering 47 V8.TFEarlyOptimization 47 effect linearization schedule V8.TFEffectLinearization 84 V8.TFStoreStoreElimination 84 **V8.TFControlFlowOptimization 84** V8.TFLateOptimization 84 **V8.TFMemoryOptimization 111** V8.TFMachineOperatorOptimization 112 V8.TFDecompressionOptimization 112 h node in V8.TFLateGraphTrimming 112 schedule before register allocation after register allocation

图4: TurboFan对IR的处理步骤

你可以看到,在第一步"v8.TFBytecodeGraphBuilder"阶段显示的IR中,它显示的节点还是有点儿多。我们先隐藏掉与计算功能无关的节点,得到了下面的主干。**你要注意其中的绿色节点**,这里已经进行了类型推测,因此它采用了一个整型计算节点:SpeculativeSafeIntegerAdd。

这个节点的功能是: 当两个参数都是整数的时候,那就符合类型推断,做整数加法操作; 如果不符合类型推断,那么就执行逆优化。

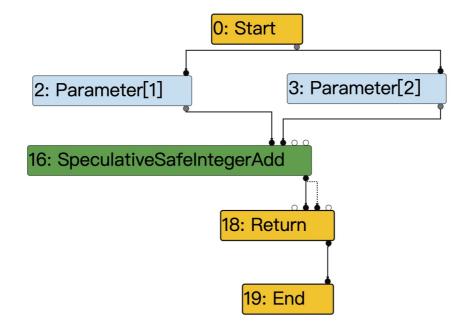


图5: v8.TFBytecodeGraphBuilder"阶段的IR

你可以再去点击其他的优化步骤,看看图形会有什么变化。

在v8.TFGenericLowering阶段,我们得到了如下所示的IR图,这个图只保留了计算过程的主干。里面增加了两个绿色节点,这两个节点就是把标记指针转换成整数的;还增加了一个深蓝色的节点,这个节点是在函数返回之前,把整数再转换成标记指针。

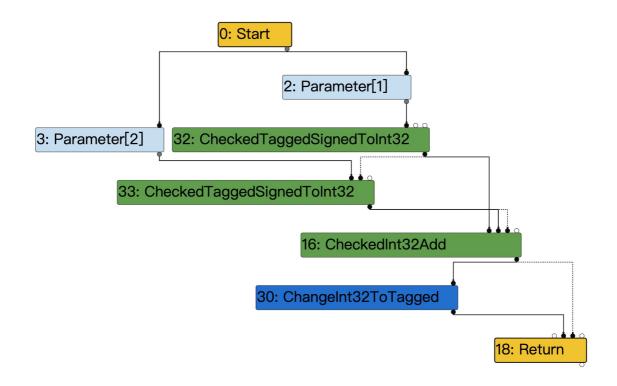


图6: v8.TFGenericLowering阶段的IR

在v8.TFLateGraphTrimming阶段,图中的节点增加了更多的细节,它更接近于具体CPU架构的汇编代码。比如,我们把前面图6中的标记指针,转换成32位整数的操作,就变成了两个节点:

- TruncateInt64ToInt32: 把64位整型截短为32位整型;
- Word32Sar: 32位整数的移位运算,用于把标记指针转换为整数。

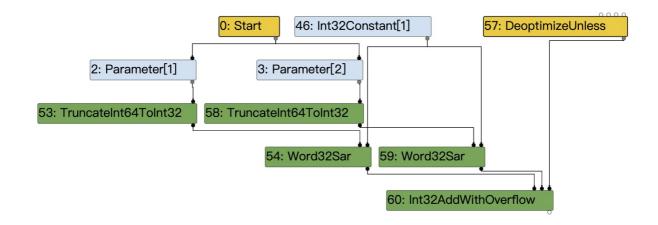


图7: v8.TFLateGraphTrimming阶段的IR

这三个阶段就形象地展示出了TurboFan的IR是如何Lower的,从比较抽象的、机器无关的节点,逐步变成 了与具体架构相关的操作。

所以,基本上IR的节点可以分为四类:顶层代表复杂操作的JavaScript节点、底层代表简单操作的机器节点、处于二者之间做了一定简化的节点,以及可以被各个层次共享的节点。

刚才我们对V8做优化编译时,所采用的IR的分析,只关注了与加法计算有关的主干节点。你还可以用同样的方法,来看看其他的节点。这些节点主要是针对异常情况的处理。比如,如果发现参数类型不是整型,那么就要去执行逆优化。

在做完了所有的优化之后,编译器就会进入指令排序、寄存器分配等步骤,最后生成机器码。

现在,你就了解了TurboFan是如何借助Sea of Nodes来做优化和Lower的了。但我们还没有涉及具体的优化算法。**那么,什么优化算法会帮助V8提升性能呢?**

前面在研究<mark>Java的JIT编译器</mark>的时候,我们重点关注了内联和逃逸分析的优化算法。那么,对于JavaScript 来说,这两种优化也同样非常重要,一样能带来巨大的优化效果。

我们先来看看**内联优化**。对于之前的示例程序,由于我们使用了"-turbo-filter=add"选项来运行代码,因此TurboFan只会编译add方法,这就避免了顶层函数把add函数给内联进去。而如果你去掉了这个选项,就会发现TurboFan在编译完毕以后,程序后面的运行速度会大大加快,一闪而过。这是因为整个顶层函数都被优化编译了,并且在这个过程中,把add函数给内联进去了。

然后再说说**逃逸分析**。V8运用逃逸分析算法,也可以像Java的编译器一样,把从堆中申请的内存优化为从 栈中申请(甚至使用寄存器),从而提升性能,并避免垃圾收集带来的消耗。

不过,JavaScript和Java的对象体系设计毕竟是不一样的。在Java的类里,每个成员变量相对于对象指针的偏移量都是固定的;而JavaScript则在内部用了**隐藏类**来表示对象的内存布局。这也引出V8的另一个有特色的优化主题:**内联缓存**。

那接下来,我就带你详细了解一下V8的隐藏类和内联缓存机制。

隐藏类(Shapes)和内联缓存(Inline Caching)

隐藏类,学术上一般叫做Hidden Class,但不同的编译器的叫法也不一样,比如Shapes、Maps,等等。

隐藏类有什么用呢?你应该知道,在JavaScript中,你不需要先声明一个类,才能创建一个对象。你可以随时创建对象,比如下面的示例程序中,就创建了几个表示坐标点的对象:

```
point1 = {x:2, y:3};
point2 = {x:4, y:5};
point3 = {y:7, x:6};
point4 = {x:8, y:9, z:10};
```

那么,V8在内部是怎么来存储x和y这些对象属性的呢?

如果按照Java的内存布局方案,一定是在对象头后面依次存放x和y的值;而如果按照Python的方案,那就需要用一个字典来保存不同属性的值。但显然用类似Java的方案更加节省内存,访问速度也更快。

所以,V8内部就采用了隐藏类的设计。如果两个对象,有着相同的属性,并且顺序也相同,那么它们就对应相同的隐藏类。

在上面的程序中,point1和point2就对应着同一个隐藏类;而point3和point4要么是属性的顺序不同,要么是属性的数量不同,对应着另外的隐藏类。

所以在这里,你就会得到一个**编写高性能程序的要点**:对于相同类型的对象,一定要保证它们的属性数量和顺序完全一致,这样才会被V8当作相同的类型,从而那些基于类型推断的优化才会发挥作用。

此外,V8还用到了一种叫做**内联缓存**的技术,来**加快对象属性的访问时间**。它的原理是这样的:当V8第一次访问某个隐藏类的属性的时候,它要到隐藏类里,去查找某个属性的地址相对于对象指针的偏移量。但V8会把这个偏移量缓存下来,这样下一次遇到同样的shape的时候,直接使用这个缓存的偏移量就行了。

比如下面的示例代码,如果对象o是上面的point1或point2,属性x的地址偏移量就是相同的,因为它们对应的隐藏类是一样的:

```
function getX(o){
  return o.x;
}
```

有了内联优化技术,那么V8只有在第一次访问某个隐藏类的属性时,速度会慢一点,之后的访问效率就跟 Java的差不多了。因为Java这样的静态类型的代码,在编译期就可以确定每个属性相对于对象地址的偏移 量。

好,现在你已经了解了TurboFan做优化的一些关键思路。接下来,我们再返回来,重新探讨一下Ignition的运行速度问题。

提升Ignition的速度

最新版本的V8已经不需要多级的编译器了,只需要一个解释器(Ignition)和一个优化编译器(TurboFan)就行。在公开的测试数据中,Ignition的运行速度,已经接近一个基线编译器生成的机器码的速度了,也就是那种没有做太多优化的机器码。

这听上去似乎不符合常理,毕竟,解释执行怎么能赶得上运行机器码呢?所以,这里一定有一些值得探究的 技术原理。

让我们再来看看Ignition解释执行的原理吧。

在上一讲中你已经了解到,V8的字节码是很精简的。比如,对于各种加法操作,它只有一个Add指令。

但是我们知道,Add指令的语义是很复杂的,比如在ECMAScript标准中,就对加法的语义有很多的规定, 如数字相加该怎么做、字符串连接该怎么做,等等。

12.8.3 The Addition Operator (+)

NOTE The addition operator either performs string concatenation or numeric addition.

12.8.3.1 Runtime Semantics: Evaluation

AdditiveExpression : AdditiveExpression + MultiplicativeExpression

- 1. Let *lref* be the result of evaluating *AdditiveExpression*.
- 2. Let *lval* be ? GetValue(*lref*).
- 3. Let *rref* be the result of evaluating *MultiplicativeExpression*.
- 4. Let *rval* be ? GetValue(*rref*).
- 5. Let *lprim* be ? ToPrimitive(*lval*).
- 6. Let *rprim* be ? ToPrimitive(*rval*).
- 7. If Type(*lprim*) is String or Type(*rprim*) is String, then
 - a. Let *lstr* be ? ToString(*lprim*).
 - b. Let *rstr* be ? ToString(*rprim*).
 - c. Return the string-concatenation of *lstr* and *rstr*.
- 8. Let *lnum* be ? ToNumeric(*lprim*).
- 9. Let rnum be? ToNumeric(rprim).
- 10. If Type(*lnum*) is different from Type(*rnum*), throw a **TypeError** exception.
- 11. Let T be Type(lnum).
- 12. Return *T*::add(*lnum*, *rnum*).

图8: ECMAScript标准中加法操作的语义规则

这样的话,V8在解释执行Add指令的时候,就要跳到一个内置的函数去执行,其他指令也是如此。这些内 置函数的实现质量,就会大大影响解释器的运行速度。

那么如果换做你,你会怎么实现这些内置函数呢?

选择1:用汇编语言去实现。这样,我们可以针对每种情况写出最优化的代码。但问题是,这样做的工作量很大。因为V8现在已经支持了9种架构的CPU,而要为每种架构编写这些内置功能,都需要敲几万行的汇编

选择2:用C++去实现。这是一个不错的选择,因为C++代码最后编译的结果也是很优化的。不过这里也有一个问题:C++有它自己的调用约定,跟V8中JavaScript的调用约定是不同的。

比如,在调用C++的内置函数之前,解释器要把自己所使用的物理寄存器保护起来,避免被C++程序破坏,在调用完毕以后还要恢复。这使得从解释器到内置函数,以及从内置函数回到解释器,都要做不少的转换工作。你还要写专门的代码,来对标记指针进行转换。而如果要使用V8的对象,那要处理的事情就更多了,比如它要去隐藏类中查找信息,以及能否通过优化实现栈上内存分配,等等。

那么,我们还有别的选择吗?

有的。你看,V8已经有了一个不错的优化编译器TurboFan。**既然它能产生很高效的代码,那么我们为什么不直接用TurboFan来生成机器码呢?**这个思路其实是可行的。这可以看做是V8编译器的一种自举能力,用自己的编译器,来生成自己内部要使用的内置函数的目标代码。

毕竟,TurboFan本来就是要处理标记指针、JavaScript对象的内存表示等这些问题。这个方案还省去了做调用约定的转换的工作,因为本来V8执行的过程中,就要不断在解释执行和运行机器码之间切换,V8内部对栈桢和调用约定的设计,就是要确保这种切换的代价最低。

在具体实现的时候,编写这些内置函数是用JavaScript调用TurboFan提供的一些宏。这些宏可以转化为 TurboFan的IR节点,从而跟TurboFan的优化编译功能无缝衔接。

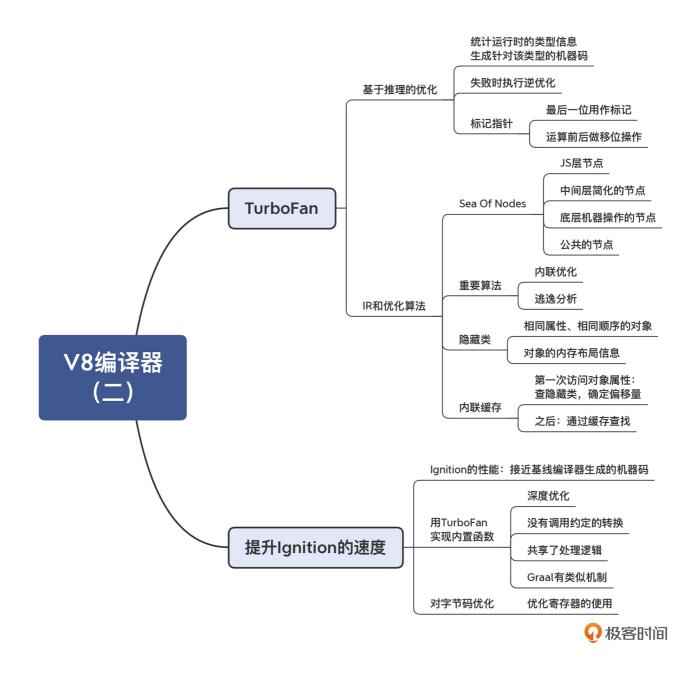
好了,分析到这里,你就知道为什么Ignition的运行速度会这么快了:**它采用了高度优化过的内置函数的实现,并且没有调用约定转换的负担。**而一个基线编译器生成的机器码,因为没有经过充分的优化,反倒并没有那么大的优势。

再补充一点,V8对字节码也提供了一些优化算法。比如,通过优化,可以减少对临时变量的使用,使得代码可以更多地让累加器起到临时变量的作用,从而减少内存访问次数,提高运行效率。如果你有兴趣在这个话题上去做深入研究,可以参考我在文末链接中给出的一篇论文。

课程小结

本讲,我围绕运行速度这个主题,给你讲解了V8在TurboFan和Ignition上所采用的优化技术。你需要记住以下几个要点:

- 第一,由于JavaScript是动态类型的语言,所以优化的要点,就是推断出函数参数的类型,并形成有针对性的优化代码。
- 第二,同Graal一样,V8也使用了Sea of Nodes的IR,而且对V8来说,内联和逃逸优化算法仍然非常重要。我在解析Graal编译器的时候已经给你介绍过了,所以这一讲并没有详细展开,你可以自己去回顾复习一下。
- 第三,V8所采用的内联缓存技术,能够在运行期提高对象属性访问的性能。另外你要注意的是,在编写 代码的时候,一定要避免对于相同的对象生成不同的隐藏类。
- 第四,Ignition采用了TurboFan来编译内置函数,这种技术非常聪明,既省了工作量,又简化了系统的结构。实际上,在Graal编译器里也有类似的技术,它叫做Snippet,也是用自身的中后端功能来编译内置函数。所以,你会再次发现,多个编译器之间所采用的编译技术,是可以互相印证的。



一课一思

我们已经学了两种动态类型的语言的编译技术: Python和JavaScript。那我现在问一个开脑洞的问题: 如果你要给Python加一个JIT编译器,那么你可以从JavaScript这里借鉴哪些技术呢? 在哪些方面,编译器会得到巨大的性能提升?

参考资料

- 1. V8的指针压缩技术: Pointer Compression in V8
- 2. 介绍V8基于推理的优化机制: An Introduction to Speculative Optimization in V8
- 3. 对Ignition字节码做优化的论文: Register equivalence optimization,我在GitHub上也放了一份拷贝

精选留言:

myrfy 2020-07-20 09:45:21
 python里的字典初始化语法和js类似,也可以用隐藏类
 因为同样是动态语言,也可以基于统计特征推断类型然后做jit优化。另外python有一个强类型约束的子集,叫RPython,没记错的话pypy解释器就是用rpython写的。另外也可以借鉴Cython为类似python的语法加类型注解,从而帮助编译器推断类型。

指针压缩好像不太适合,因为Python的一大特点就是作为胶水语言,很多高性能的工作都是第三方c库实现的,c-ffi调用很频繁,所以采用大家通用的指针表达方式会好一些