28-前端总结: 语言设计也有人机工程学

你好,我是宫文学。

正如我在上一讲的"课程导读"中所提到的,在"现代语言设计篇",我们会开始探讨现代语言设计中的一些典型特性,包括前端、中后端、运行时的特性等,并会研究它们与编译技术的关系。

今天这一讲,我先以前面的"真实编译器解析篇"所分析的7种编译器作为基础,来总结一下它们的前端技术的特征,为你以后的前端工作做好清晰的指引。

在此基础上,我们还会进一步讨论语言设计方面的问题。近些年,各种新语言都涌现出了一个显著特征,那就是越来越考虑对程序员的友好性,运用了人机工程的思维。比如说,自动类型推导、Null安全性等。那么在这里,我们就一起来分析一下,要支持这些友好的语法特征,在编译技术上都要做一些什么工作。

好,首先,我们就来总结一下各个编译器的前端技术特征。

前端编译技术总结

通过前面课程中对7个编译器的解读分析,我们现在已经知道了,编译器的前端有一些共性的特征,包括: 手写的词法分析器、自顶向下分析为主的语法分析器和差异化的语义分析功能。

手写的词法分析器

我们分析的这几个编译器,全部都采用了手写的词法分析器。主要原因有几个:

- 第一,手写的词法分析实现起来比较简单,再加上每种语言的词法规则实际上是大同小异的,所以实现起来也都差不多。
- 第二,手写词法分析器便于做一些优化。典型的优化是把关键字作为标识符的子集来识别,而不用为识别每个关键字创建自动机。V8的词法分析器还在性能上做了调优,比如判断一个字符是否是合法的标识符字符,是采用了查表的方法,以空间换性能,提高了解析速度。
- 第三,手写词法分析器便于处理一些特殊的情况。在 MySQL的词法分析器中,我们会发现,它需要根据当前字符集来确定某个字符串是否是合法的Token。如果采用工具自动生成词法分析器,则不容易处理这种情况。

结论:如果你要实现词法分析器,可以参考这些编译器,来实现你自己手写的版本。

自顶向下分析为主的语法分析器

在"解析篇"中,我们还见到了多个语法分析器。

手写 vs 工具生成

在前面解析的编译器当中,大部分都是手写的语法分析器,只有Pvthon和MvSOL这两个是用工具生成的。

一方面,手写实现能够在某些地方做一些优化的实现,比如在Java语言里,我们可以根据需要,预读一到 多个Token。另外,手写实现也有利于编译错误的处理,这样可以尽量给用户提供更友好的编译错误信息, 并且当一个地方发生错误以后,也能尽量不影响对后面的语句的解析。手写的语法分析器在这些方面都能提 供更好的灵活性。

另一方面,Python和MySQL的编译器也证明了,用工具生成的语法分析器,也是完全可以用于高要求的产品之中的。所以,如果你的项目时间和资源有限,你要优先考虑用工具生成语法分析器。

自顶向下 vs 自底向上

我们知道,语法分析有两大算法体系。一是自顶向下,二是自底向上。

从我们分析过的7种编译器里可以发现,**自顶向下的算法体系占了绝对的主流**,只有MySQL的语法分析器, 采用的是自底向上的LALR算法。

而在自顶向下的算法中,又几乎全是采用了递归下降算法,Java、JavaScript和Go三大语言的编译器都是如此。并且对于左递归这个技术点,我们用标准的改写方法就可以解决。

不过,我们还看到了自顶向下算法和自底向上算法的融合。Java语言和Go语言在处理二元表达式时,引入了运算符优先级解析器,从而避免了左递归问题,并且在处理优先级和结合性的问题上,也会更加容易。而运算符优先级解析器,实际上采用的是一种LR算法。

差异化的语义分析功能

不同编译器的语义分析功能有其共性,那就是都要建立符号表、做引用消解。对于静态类型的语言来说,还一定要做类型检查。

语义分析最大的特点是**上下文相关**,AST加上这些上下文相关的关系,就从树变成了图。由于处理图的算法一般比较复杂,这就给引用消解带来了困难,因此我们在算法上必须采用一定的启发式规则,让算法简化。

比如,我们可以先把类型加入符号表,再去消解用到这些类型的地方:变量声明、方法声明、类继承的声明,等等。你还需要注意的是,在消解本地变量的时候,还必须一边消解,一边把本地变量加入符号表,这样才能避免形成错误的引用关系。

不过,在建立符号表,并做完引用消解以后,上下文相关导致的复杂性就被消除了。所以,后续的语义分析算法,我们仍然可以通过简单地遍历AST来实现。所以,你会看到这些编译器当中,大量的算法都是实现了 Visitor模式。

另外,除了建立符号表、做引用消解和类型检查等语义分析功能,不同的编译器还要去处理自己特有的语义。比如说,Java编译器花了很多的工作量在处理语法糖上,还有对注解的处理上; Julia的编译器会去做类型推断; Python的编译器会去识别变量的作用域范围,等等。

这其中,很多的语义处理功能,都是为了支持更加友好的语言特性,比如Java的语法糖。在现代语言中,还增加了很多的特性,能够让程序员的编程工作更加容易。接下来,我就挑几个共性的特性,跟你一起探讨一下它们的实现。

支持友好的语言特性

自动类型推导、Null安全性、通过语法糖提高语法的友好性,以及提供一些友好的词法规则,等等。这些都是现代语言努力提高其友好性的表现。

自动类型推导

自动类型推导可以减少编程时与类型声明有关的工作量。我们来看看下面这几门语言,都是如何声明变量的。

C++语言是一门不断与时俱进的语言。在C++ 11中,采用了auto关键字做类型推导。比如:

```
int a = 10;
auto b = a; //能够自动推导b的类型是int
cout << typeid(b).name() << endl; //输出int
```

你可能会觉得,这看上去似乎也没啥呀,把int换成了auto好像并没有省多少事儿。但在下面这个例子中,你会发现用于枚举的变量的类型很长(std::vector<std::string>::iterator),那么你就大可以直接用一个auto来代替,省了很多事,代码也更加整洁。所以实际上,auto关键字也成为了在C++中使用枚举器的标准用法:

我们接着来看看其他的语言,都是如何做类型推导的。

Kotlin中用var声明变量,也支持显式类型声明和类型推导两种方式。

```
var a : Int = 10; //显式声明
var b = 10; //类型推导
```

Go语言, 会用":=" 让编译器去做类型推导:

而Swift语言是这样做的:

实际上,连Java语言也在Java 10版本加上了类型推导功能,比如:

```
Map<String, User> a = new HashMap<String, User>(); //显式声明
var b = new HashMap<String, User>(); //类型推导
```

你在学习了语义分析中,**基于属性计算做类型检查的机制**以后,就会发现实现类型推导,其实是很容易的。 只需要把等号右边的初始化部分的类型,赋值给左边的变量就行了。

可以看到,在不同的编译器的实现当中,类型推导被如此广泛地接受,所以如果你要设计一门新的语言,你 也一定要考虑类似的做法。

好,我们接着再来探讨下一个有趣的特性,它叫做"Null安全性"。

Null安全性

在C++和Java等语言里,会用Null引用,来**表示某个变量没有指向任何对**象。这个特性使得语言里充满了Null检查,否则运行时就会报错。

给你举个例子。下面这段代码中,我们想要使用student.teacher.name这个成员变量,因此程序要逐级检查student、teacher和name是否为Null。不检查又不行,检查又太啰嗦。你在自己写程序的时候,肯定也遇到过这种困扰。

```
if (student != null
   && student.teacher != null
   && student.teacher.name !=null){
   ...
}
```

Null引用其实是托尼·霍尔(Tony Hoare)在1960年代在设计某一门语言(ALGOL W)时引入的,后来也纷纷被其他语言所借鉴。但Hoare后来却认为,这是一个"价值亿万美元的错误",你可以看看他在QCon上的演讲。因为大量的软件错误都是由Null引用引起的,而计算机语言的设计者本应该从源头上消除它。

其实我觉得Hoare有点过于自责了。因为在计算机语言发展的早期,很多设计决定的后果都是很难预料的, 当时的技术手段也很有限。而在计算机语言已经进化了这么多年的今天,我们还是有办法消除或者减少Null 引用的不良影响的。

以Kotlin为例,在缺省情况下,它不允许你把Null赋给变量,因此这些变量就不需要检查是否为Null。

```
var a : String = "hello";
a = null; //报编译错误
```

不过有的时候,**你确实需要用到Null,那该怎么办?**

你需要这样的声明变量,在类型后面带上问号,告诉编译器这个变量可为空:

```
var a : String? = "hello";
a = null; //OK
```

但接下来,如果你要使用a变量,就必须进行Null检查。这样,编译器会跟踪你是否做了所有的检查。

```
val l = b.length; //编译器会报错,因为没有做null检查

if (b != null){
    println(b.length); //OK,因为已经进行了null检查
}
```

或者,你可以进行**安全调用**(Safe Call),采用**"?."操作符**来访问b.length,其返回值是一个Int?类型。 这样的话,即使b是Null,程序也不会出错。

```
var 1 : Int? = b?.length;
```

并且,如果你下一步要使用l变量的话,就要继续进行Null的检查。编译器会继续保持跟踪,让整个过程不会有漏洞。

而如果你对一个本身可能为Null的变量赋值,编译器会生成Null检查的代码。如果该变量为Null,那么赋值操作就会被取消。

在下面的示例代码中,如果student或是teacher,或者是name的值为Null,赋值操作都不会发生。这大大减少了那种啰嗦的Null检查:

```
student?.teacher?.name=course.getTeacherName();
```

你可以看到,Kotlin通过这样的机制,就大大降低了Null引用可能带来的危害,也大大减少了Null检查的代码量,简直是程序员的福音。

而且,不仅是Kotlin语言具有这个特性,Dart、Swift、Rust等新语言都提供了Null安全性。

那么,Null安全性在编译器里应该怎样实现呢?

最简单的,你可以给所有的类型添加一个属性: **Nullable**。这样就能区分开Int?和Int类型,因为对于后者来说,Null不是一个合法的取值。之后,你再运用正常的属性计算的方法,就可以实现Null安全性了。

接下来,我们再看看现代语言会采用的一些语法糖,让语法更友好。

一些友好的语法糖

1.分号推断

分号推断的作用是在编程的时候,让程序员省略掉不必要的分号。在Java语言中,我们用分号作为一个语句的结尾。而像Kotlin等语言,在一个语句的最后,可以加分号,也可以不加。但如果两个语句在同一行,那么就要加分号了。

2.单例对象

在程序中,我们经常使用单例的数据模式。在Java、C++等语言中,你需要写一些代码来确保只生成类的一个实例。而在Scala、Kotlin这样的语言中,可以直接声明一个单例对象,代码非常简洁:

```
object MyObject{
  var field1...
  var field2...
}
```

3. 纯数据的类

我们在写程序的时候,经常需要处理一些纯粹的数据对象,比如数据库的记录等。而如果用传统的类,可能编写起来会很麻烦。比如,使用Java语言的话,你需要为这些类编写toString()方法、hashCode()方法、equals()方法,还要添加很多的setter和getter方法,非常繁琐。

所以,在JDK 14版本,就增加了一个实验特性,它可以**支持Record类**。比如,你要想定义一个Person对象,只需要这样一句话就行了:

```
public record Person(String firstName, String lastName, String gender, int age){}
```

这样一个语句,就相当于下面这一大堆语句:

```
public final class Person extends Record{
  private final String firstName;
```

```
private final String lastName;
 private final String gender;
 private final int age;
 public Person(String firstName, String lastName, String gender, int age){
   this.firstName = firstName;
   this.lastName = lastName;
   this.gender = gender;
   this.age = age;
 public String getFirstName(){
   return this.firstName;
 public String getLastName(){
   return this.lastName;
 public String getGender(){
   return this.gender;
 public String getAge(){
   return this.age;
 pulic String toString(){
 public boolean equals(Object o){
 public int hashCode(){
 }
}
```

所以你可以看到,Record类真的帮我们省了很多的事儿。Kotlin也有类似的data class,而Julia和Swift内置支持元组,对纯数据对象的支持也比较好。

4.没有原始类型,一切都是对象

像Java、Go、C++、JavaScript等面向对象的语言,既要支持基础的数据类型,如整型、浮点型,又要支持对象类型,它们对这两类数据的使用方式是不一致的,因此也就增加了我们的编程负担。

而像Scala、Kotlin等语言,它们可以把任何数据类型都看作是对象。比如在Kotlin中,你可以直接调用一个整型或浮点型数字的方法:

```
[>>> 2.dec()
res1: kotlin.Int = 1
[>>> 8.div(3)
res2: kotlin.Int = 2
[>>> 8.0.div(3)
res3: kotlin.Double = 2.66666666666665
>>>
```

不过你要注意的是,如果你要把基础数据类型也看作是对象,在编译器的实现上要做一些特殊的处理,因为如果把这些基础数据当作普通对象一样保存在堆里,那显然要占据太多的空间(你可以回忆一下Java对象 头所需要的空间),并且访问性能也更低。

那么要如何解决这些问题呢? 这里我先留一个伏笔,我们在"综合实现(一):如何实现面向对象编程?"这一讲再来讨论吧!

除了语法上的一些友好设计之外,一些现代语言还在词法规则方面,提供了一些友好的设计。我们一起来看一下。

一些友好的词法规则

1.嵌套的多行注释

编程语言一般都支持多行注释。比如,你可以把暂时用不到的一段代码给注释起来。这些代码里如果有单行 注释也不妨碍。

但是,像Kotlin、Swift这些语言又更进了一步,它们可以支持在多行注释里嵌套多行注释。这是一个很贴心的功能。这样的话,你就可以把连续好几个函数或方法给一起注释掉。因为函数或方法的头部,一般都有多行的头注释。支持嵌套注释的话,我们就可以把这些头注释一起包含进去。

你可以去看看它们的词法分析器中处理注释的逻辑,了解下它们是如何支持嵌套的多行注释的。

2.标识符支持Unicode

现代的大部分语言,都支持用Unicode来声明变量,甚至可以声明函数或类。这意味着什么呢? **你可以用中文来声明变量和函数名称**。而对于科学工作者来说,你也可以使用 π 、 α 、 β 、 θ 这些希腊字母,会更符合自己的专业习惯。下面是我在Julia中使用Unicode的情况:

```
[julia> pi
π = 3.1415926535897...

[julia> 姓名="宫文学"

"宫文学"

[julia> function 求和(x, y)

[ x + y

[ end

求和 (generic function with 1 method)

[julia> 求和(2,π)

5.141592653589793
```

3.多行字符串字面量

对于字符串字面量来说,支持多行的书写方式,也会给我们的编程工作带来很多的便利。比如,假设你要把一个JSON字符串或者一个XML字符串赋给一个变量,用多行的书写方式会更加清晰。如下所示:

```
[julia> a = """
[ "city":"北京"
[ "name":"宫文学"
[ """
"\"city\":\"北京\"\n\"name\":\"宫文学\"\n"
```

现在,很多的编程语言都可以支持多行的字符串字面量,比如:

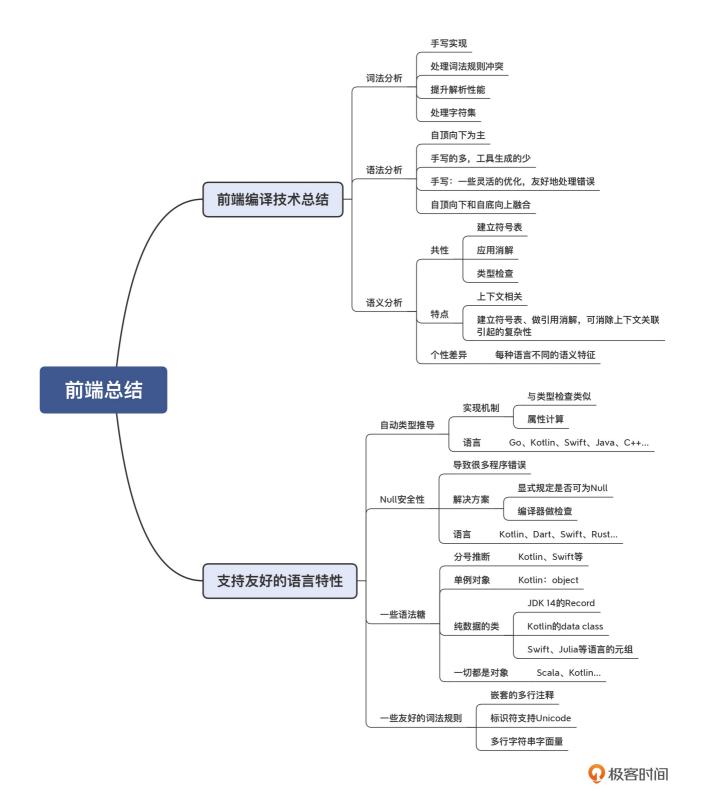
语言	起止符号		
Go	`		
Python	""" 或 ""		
Swift	1111		
Kotlin	1111		
Julia	1111		
Scala	11111		

课程小结

今天这一讲,我带你一起总结了一下编译原理的前端技术。在解析了这么多个编译器以后,你现在对于实现 前端功能时,到底应该选择什么技术、不同的技术路线有什么优缺点,就都心里有数了。

另外,很多我们可以感知得到的现代语言特性,都是一些前端的功能。比如,更友好的词法特性、更友好的语法特性,等等。你可以借鉴当前语言的一些最佳实践。以你现在的知识积累来说,理解上述语言特性在前端的实现过程,应该不难了。如果你对哪个特性特别感兴趣,也可以按照课程的思路,去直接研究它的编译器。

最后,我把本讲的思维导图也整理了出来,供你参考:



一课一思

你比较推崇哪些友好的前端语言特性?它们是怎么实现的?欢迎在留言区分享你的看法。另外,如果你觉得哪些前端特性的设计是失败的,也可以拿来探讨,我们共同吸取教训。

感谢你的阅读,欢迎你把今天的内容分享给更多的朋友。